

2022 中国系统架构师大会

SYSTEM ARCHITECT CONFERENCE CHINA 2022

:激发架构性能 点亮业务活力

△ 云上会议 网络直播 | ● 2022年10月27-29日











深度学习平台建设中的性能优化实践

竞技世界 - 胡文晖











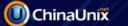
主要内容

- 平台建设中的任务模板
- 数据处理
- 数据输入管线
- 模型训练
- 小结











平台的建设需求

• 现状:资源划归到个人

- 算力碎片化:采购成本,资源闲置

- 存储碎片化:共享困难,安全性差

- 任务重现困难:环境,参数,版本

- 任务运行效率:软件框架,编程模式

- 项目可维护性:复制粘贴,过度封装

-

• 目标: 提高资源利用率

- 统一分配的算力
- 集中管理的存储
- 任务可重现
- 兼容软件框架升级
- 一代码规范,贴近最佳实践









平台的基本功能

• 管理集群资源

- 统一分配的算力:资源分配,任务启动,状态监控,资源回收,……
- 集中管理的存储: 共享存储, 对象存储, 日志,
- 任务可重现:元数据,记录启动信息,运行时状态,……
- 兼容软件框架升级:任务模板
- 代码规范,贴近最佳实践:任务模板









任务模板的作用

- 采用软件框架的形式,实现具体业务的逻辑
 - 剥离于具体业务,可以单独优化
 - 贴近框架的最佳实践,执行效率较高
 - 能够得益于框架升级,获得性能提升与功能扩展
 - 满足编码规范,可维护性较强
 - 促进知识积累









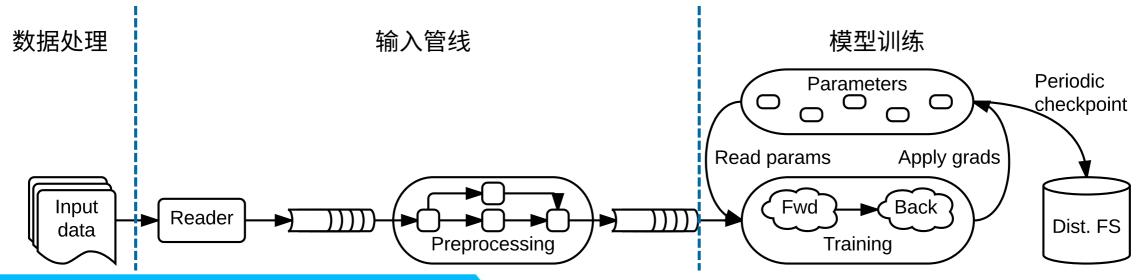


深度(监督)学习任务的基本步骤

• 数据处理: 生成数据集

• 输入管线: 读取 / 预处理为训练数据

• 模型训练: 前 / 后向传播并更新权重











数据处理

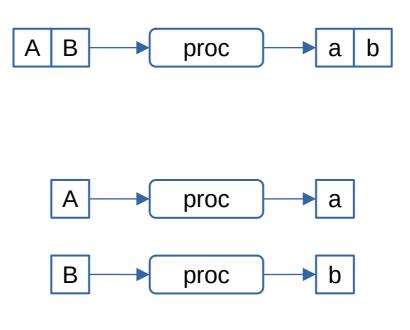
需求: 文件 → 文件



- 并行处理,按需选择粒度
- 共享存储,文件系统可访问
- 存储格式,速度/空间平衡

• 多次运行:

- 数据类型,统计分布



数据处理逻辑
并行处理模板
并行软件框架
.....







数据输入管线

- 为模型训练提供数据: 读取数据集,将样本转换为特征
 - 多步骤串行处理,多样本并行处理
- 训练启动延迟:依赖于处理流程,会降低吞吐







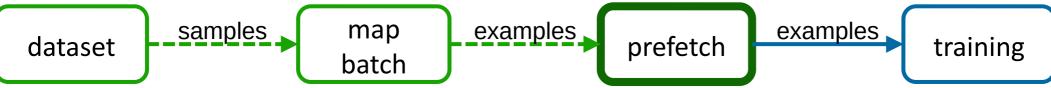




数据输入管线

- 在管线末端增加缓冲区
 - 训练启动后直接读取,无需等待
 - 处理流程采用后台多线程 / 多进程
- 训练启动延迟: 与处理流程无关

数据预处理逻辑 输入管线模板 相应软件框架 training







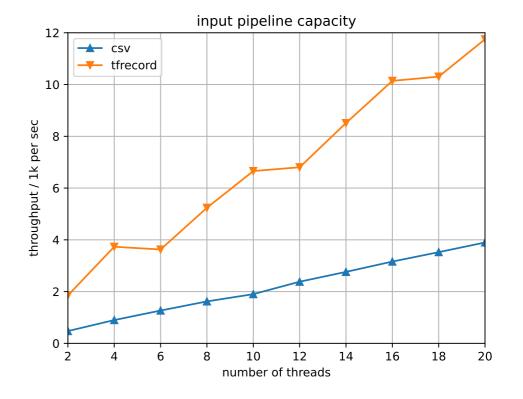
168.





数据输入管线

- 不同存储格式的读取性能
 - plain text, gzip 压缩比大约 40
 - csv ,读取文本行,解析格式
 - tfrecord ,读取字节流,反序列化





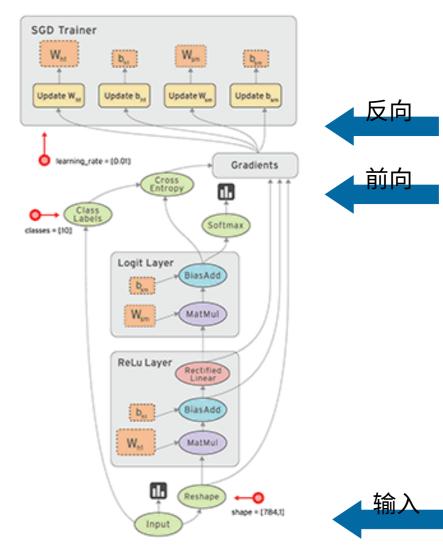






深度神经网络

- 有向无环图(计算图)
 - 边,对应数据传递
 - 节点,对应数据操作
 - 依次执行
- 并行处理
- 分布式(异构)执行
- 编译时优化



168.00









模型训练

- 模型创建: 构建计算图
 - 前向过程,记录模型结构
 - 反向过程,记录模型权重的更新方式
- 模型训练: 依赖于执行引擎
- 将业务逻辑表示为计算图,然后由执行引擎处理











模型(计算图)构建

- 低层 API: 对应于基础操作
 - 可执行的算子,数学操作/类型转换/输入输出/控制流/.....
 - 功能稳定,灵活度高
 - 开发复杂
- 高层 API: 封装的功能模块
 - 神经网络组件,层 / 模型 / 损失函数 / 优化器 /.....
 - 相对稳定,易用性强
 - 开发迅速





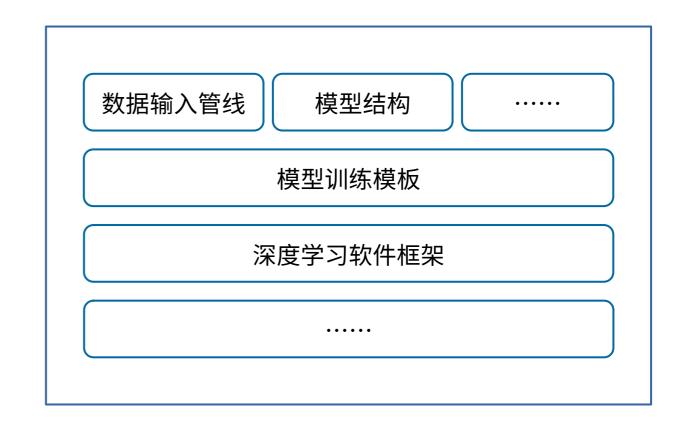






模型训练

- 构建计算图: 规范化输入
 - 数据输入管线
 - 模型结构
 - 训练步
 -
- 由执行引擎负责图的执行











模型训练

- 软件框架功能升级:
 - 即时编译
 - 混合精度
 - 分布式训练
 -

| | 直接运行 | 即时编译 | 即时 + 混合 |
|---------|------|------|---------|
| 原始代码 | 2761 | 3243 | 不可用 |
| 模板 | 3079 | 3168 | 5205 |
| 模板 + 分布 | 4662 | 4565 | 6087 |









小结

- 规范的任务模板,可以促进业务逻辑与运行时框架的分离
- 可以多次运行数据处理任务以满足需求
- 流水线缓冲可以提升数据输入管线的能力
- 充分发挥软件框架的优势







